Modelagem e Busca Linear
Paleta de cores e funções de teste

Tiago
Ciência de Dados – Universidade Federal do Ceará
Programação Não Linear – Professor Ricardo Coelho

24 de outubro de 2026

1 Parte 1: modelagem de uma paleta de três cores

1.1 Problema, dados e variáveis

O problema é uma aplicação de **quantização de cores por agrupamento**, abordagem conhecida na literatura e discutida por Celebi [1]. A modelagem apresentada é uma adaptação desse problema e de uma formulação suave de agrupamento existente, não uma proposta matemática original.

Busca-se representar uma fotografia por três cores, minimizando o erro RGB dos pixels. Utilizou-se a imagem `nascer do sol rio de janeiro.jpeg`, do acervo pessoal do autor. A original, de 3024×4032 pixels, foi convertida para RGB e reduzida com LANCZOS para 192×256, preservando a proporção. Cada componente foi dividida por 255, produzindo $N = 49\,152$ pixels fixos $p_i \in [0,1]^3$, com valores adimensionais.

As variáveis são as três cores $c_j = (R_j, G_j, B_j)^T$ da paleta:

$$x = (R_1, G_1, B_1, R_2, G_2, B_2, R_3, G_3, B_3)^T \in \mathbb{R}^9.$$

1.2 Função objetivo irrestrita

O erro por associação à cor mais próxima é $E(x) = N^{-1} \sum_i \min_j \|p_i - c_j\|^2$. Como esse mínimo pode não ser diferenciável nos empates, utiliza-se a forma de energia livre do agrupamento por *deterministic annealing* apresentada por Rose [2, eq. (25)], especializada para este recorte:

$$\min_{x \in \mathbb{R}^9} f_\tau(x), \qquad f_\tau(x) = -\frac{\tau}{N} \sum_{i=1}^{N} \log \left[\frac{1}{3} \sum_{j=1}^{3} \exp\left(-\frac{\|p_i - c_j\|^2}{\tau} \right) \right], \tag{1}$$

Na formulação de referência, tomam-se pesos dos dados iguais a $1/N$, três representantes com pesos fixos $1/3$, distância quadrática no RGB e temperatura $T = \tau$. Essas escolhas produzem a Equação 1. Aqui, $\tau = 0{,}005$ permanece fixo e executa-se um passo com Goldstein; não se implementa o processo completo de redução gradual de temperatura de Rose. A aproximação é suave e satisfaz $E \le f_\tau \le E + \tau \log 3$, com $\tau \log 3 \simeq 0{,}00549306$. As exponenciais são avaliadas com deslocamento pelo menor valor de distância, para estabilidade numérica.

O problema é irrestrito: projetar qualquer cor no cubo $[0,1]^3$ não aumenta sua distância a nenhum pixel, portanto não aumenta o objetivo. Pela continuidade e compacidade, existe um mínimo no cubo que também é global no domínio irrestrito. Isso não garante que a busca local o alcance. As variáveis não são recortadas durante a otimização.

1.3 Gradiente e Hessiana

Definindo $r_{ij} = c_j - p_i$ e

$$q_{ij} = \frac{e^{-\|r_{ij}\|^2/\tau}}{\sum_{\ell=1}^{3} e^{-\|r_{i\ell}\|^2/\tau}},$$

a regra da cadeia fornece os blocos do gradiente:

$$g_j = \nabla_{c_j} f_\tau = \frac{2}{N} \sum_i q_{ij} r_{ij}.$$

Como

$$\nabla_{c_k} q_{ij} = -\frac{2}{\tau} q_{ij}(\delta_{jk} r_{ij} - q_{ik} r_{ik}),$$

a regra do produto resulta nos blocos 3×3 da Hessiana:

$$H_{jk} = \frac{2\delta_{jk}}{N} \sum_i q_{ij} I_3 - \frac{4}{N\tau} \sum_i (\delta_{jk} q_{ij} - q_{ij} q_{ik}) r_{ij} r_{ik}^T.$$

Empilham-se os três g_j em um vetor e os nove H_{jk} em uma matriz 9×9. O delta δ_{jk} vale 1 para $j = k$ e 0 nos demais casos. Diferenças centrais com $h = 10^{-5}$, na paleta inicial e em uma paleta perturbada, produziram erros absolutos máximos inferiores a $4{,}15 \times 10^{-11}$ no gradiente e $1{,}43 \times 10^{-9}$ na Hessiana.

1.4 Convexidade

Sejam $\bar{p}$ a média dos pixels e $S = N^{-1} \sum_i (p_i - \bar{p})(p_i - \bar{p})^T$. No ponto $c_1 = c_2 = c_3 = \bar{p}$, o gradiente é zero. Para $v = (a, -a, 0)$, com $\|a\| = 1$,

$$v^T H v = \frac{4}{3} - \frac{8}{3\tau} a^T S a.$$

Escolhendo um autovetor de $\lambda_{\max}(S) = 0{,}1368844167$, obtém-se $v^T H v = -71{,}6716889305 < 0$. Há também direções de curvatura positiva nesse ponto; logo, ele é uma sela e f_τ não é globalmente convexa. Na paleta inicial, a Hessiana é numericamente definida positiva (menor autovalor 0,0092642542), indicando convexidade estrita em uma vizinhança suficientemente pequena, sem implicar convexidade global.

1.5 Primeiro passo de descida

A paleta inicial foi obtida ordenando os pixels pela média dos componentes RGB e selecionando os percentis 10, 50 e 90. Cada linha das matrizes abaixo é uma cor; x_0 e x_1 empilham suas linhas:

$$C_0 = \begin{pmatrix} 0{,}07843137 & 0{,}17647059 & 0{,}25490196 \\ 0{,}54901961 & 0{,}47843137 & 0{,}49019608 \\ 0{,}76470588 & 0{,}72941176 & 0{,}66666667 \end{pmatrix},$$

$$C_1 = \begin{pmatrix} 0{,}12157864 & 0{,}20172708 & 0{,}26495457 \\ 0{,}54173215 & 0{,}48925441 & 0{,}49788293 \\ 0{,}74215063 & 0{,}71652582 & 0{,}66821411 \end{pmatrix}.$$

Usou-se $d_0 = -\nabla f_\tau(x_0)$, com $g_0^T d_0 = -\|g_0\|^2 = -0{,}003507146131 < 0$. A busca de Goldstein, implementada diretamente, usa $c_G = 0{,}1$ e aceitou a primeira tentativa $\alpha_0 = 1$. As duas condições foram satisfeitas:

$$\underbrace{0{,}028970550720}_{f_0+(1-c_G)\alpha_0 g_0^T d_0} \leq f_\tau(x_1) = 0{,}029618187484 \leq \underbrace{0{,}031776267624}_{f_0+c_G\alpha_0 g_0^T d_0}.$$

Assim, $x_1 = x_0 + \alpha_0 d_0$ e

$$f_\tau(x_0) = 0{,}032126982237 > f_\tau(x_1) = 0{,}029618187484,$$

com redução de 7,8090%, sem recorte das variáveis. O erro de reconstrução E, medido separadamente, passou de 0,026729621032 para 0,024228079500.



Figura 1: Fotografia de trabalho, reconstruções e paletas antes e após um passo. Fonte da fotografia: acervo pessoal do autor.

A reconstrução mantém regiões gerais claras e escuras, mas perde detalhes e os tons alaranjados. Uma única fotografia reduzida, uma paleta de três cores e um passo limitam a fidelidade. O erro no RGB não é uma métrica perceptual; redução do objetivo suave não garante melhora visual ou otimalidade global. A convergência completa não é exigida nesta etapa.

2 Parte 2: experimentos de busca linear

2.1 Funções de teste e parametrização unidimensional

Foram executadas 27 combinações independentes: TP 1, TP 8 e TP 15, três direções (G, N, M) e três buscas (Fibonacci, interpolação quadrática/cúbica e Goldstein). Os pontos iniciais do enunciado são $(8, 9)$, $(0, 0)$ e $(-1{,}2, 1)$, respectivamente.

Para cada direção aplicada d, sejam $u(\alpha) = u_0 + \alpha d_1$ e $v(\alpha) = v_0 + \alpha d_2$. As funções $\phi(\alpha) = f(x_0 + \alpha d)$ são

$$\begin{aligned}
\phi_1(\alpha) &= 4[u(\alpha) - 5]^2 + [v(\alpha) - 6]^2, \\
\phi_8(\alpha) &= \sum_{k=1}^{3} [b_k - u(\alpha)(1 - v(\alpha)^k)]^2, \quad b = (1{,}5, 2{,}25, 2{,}625), \\
\phi_{15}(\alpha) &= \{10[u(\alpha) - v(\alpha)^2]^2 + [u(\alpha) - 1]^2\}^{1/4}.
\end{aligned}$$

As derivadas foram implementadas analiticamente e verificadas por diferenças centrais nos pontos padrão e extras, com erros escalados inferiores a $1{,}1 \times 10^{-10}$ no gradiente e $8{,}6 \times 10^{-11}$ na Hessiana. A TP 15 não é diferenciável em $(1, 1)$ e $(1, -1)$; o código rejeita suas derivadas nesses pontos.

2.2 Direções, métodos e parâmetros

Com $g = \nabla f(x_0)$ e $H = \nabla^2 f(x_0)$, calculam-se

$$d_G = -g, \qquad H d_N = -g, \qquad (H + \mu I) d_M = -g,$$

resolvendo sistemas lineares, sem formar inversas. Adotou-se

$$\delta = \max\{10^{-6}, 10^{-2} \max(1, \max_i |\lambda_i(H)|)\}, \quad \mu = \max(0, \delta - \lambda_{\min}(H)).$$

A matriz modificada é definida positiva. A descida numérica exige $g^T d < -10^{-12} \max(1, \|g\| \|d\|)$. Se Newton clássico falha, registra-se o diagnóstico e aplica-se M, conforme o enunciado:

- TP 1: $\mu = 0$; N e M coincidem.
- TP 8: $d_N = (0, 4{,}25)^T$, $g^T d_N = 0$ e custo constante na linha; usa-se M com $\mu \simeq 1{,}3150671$.
- TP 15: $d_N = (-4, 4, 0)^T$ e $g^T d_N \simeq 2{,}7012172328 > 0$; usa-se M com $\mu \simeq 0{,}21697093$.

As seis linhas N substituídas por M pertencem à matriz de atribuição, mas não representam sucesso da direção original nem trajetórias distintas das linhas M correspondentes.

Para Fibonacci e interpolação, uma tentativa inicial 1 é reduzida pela metade até diminuir o custo; depois é dobrada até obter $a < b < c$ com um vale amostrado, limitado a 80 tentativas. Não se presume unimodalidade nem mínimo global nas funções não convexas.

- **Fibonacci:** redução de intervalo com razões de números de Fibonacci, reaproveitamento de avaliações e largura final $\leq 10^{-7}$. A última comparação evita gerar pontos coincidentes.

- **Interpolação Q/C:** alterna mínimos de quadráticos interpoladores e cúbicos de Hermite; candidatos inadequados são substituídos por um ponto médio. Parada: largura $\leq 10^{-7}\max(1, |\alpha|)$ ou 300 tentativas.
- **Goldstein:** verifica ambas as desigualdades com $c_G = 0{,}1$, tentativa inicial 1, expansão/redução e limite de 100 tentativas.

As buscas foram implementadas sem rotinas prontas e conferidas em quadráticas com mínimos conhecidos. Na TP 1, a referência analítica é $\alpha_* = -g^T d/(d^T H d)$. Cada caso parte de seu próprio x_0 e retorna um único próximo ponto $x_1 = x_0 + \alpha d$.

2.3 Resultados e discussão

As tabelas apresentam os 27 casos. N/M indica N solicitado e M aplicado; f/g conta avaliações de custo/gradiente direcional, incluindo o intervalo e o custo em zero, com reaproveitamento por cache. As derivadas iniciais usadas para formar as direções não entram nesses contadores. A rotina de gradiente do cúbico também retorna a Hessiana, embora a busca não a use.

Tabela 1: TP 1: nove casos padrão; custo inicial 45.

Sol./usada	Busca	α	$x_1 = (u_1, v_1)$	$f(x_1)$	f/g
G/G	Fib.	0,13076922	(4,86154; 8,21538)	4,9846154	39/0
G/G	Q/C	0,13076923	(4,86154; 8,21538)	4,9846154	38/29
G/G	Gold.	0,125	(5; 8,25)	5,0625	5/0
N/N	Fib.	1	(5; 6)	$3{,}9443045 \times 10^{-30}$	40/0
N/N	Q/C	1	(5; 6)	0	52/48
N/N	Gold.	1	(5; 6)	0	2/0
M/M	Fib.	1	(5; 6)	$3{,}9443045 \times 10^{-30}$	40/0
M/M	Q/C	1	(5; 6)	0	52/48
M/M	Gold.	1	(5; 6)	0	2/0

Tabela 2: TP 8: nove casos padrão; custo inicial 14,203125.

Sol./usada	Busca	α	$x_1 = (u_1, v_1)$	$f(x_1)$	f/g
G/G	Fib.	0,16666667	(2,125; 0)	0,65625	38/0
G/G	Q/C	0,16666667	(2,125; 0)	0,65625	48/43
G/G	Gold.	0,25	(3,1875; 0)	4,0429688	4/0
N/M	Fib.	0,020386452	(0,5515; −1,25811)	7,6282475	36/0
N/M	Q/C	0,020386444	(0,5515; −1,25811)	7,6282475	28/13
N/M	Gold.	0,0234375	(0,634038; −1,4464)	8,6656561	9/0
M/M	Fib.	0,020386452	(0,5515; −1,25811)	7,6282475	36/0
M/M	Q/C	0,020386444	(0,5515; −1,25811)	7,6282475	28/13
M/M	Gold.	0,0234375	(0,634038; −1,4464)	8,6656561	9/0

Todos os casos produziram redução estrita. Na TP 1, N e M atingiram $(5, 6)$ com passo igual ou numericamente próximo de 1; o resíduo de Fibonacci é de arredondamento. Na TP 8, G mantém $v = 0$ e o mínimo da linha ocorre em $\alpha = 1/6$, com custo 0,65625,

Tabela 3: TP 15: nove casos padrão; custo inicial 2,701217233.

Sol./usada	Busca	α	$x_1 = (u_1, v_1)$	$f(x_1)$	f/g
G/G	Fib.	1,2043933	$(-0{,}460607; -0{,}34435)$	1,5305656	41/0
G/G	Q/C	1,2043933	$(-0{,}460607; -0{,}34435)$	1,5305656	30/18
G/G	Gold.	1	$(-0{,}586087; -0{,}116205)$	1,5722581	2/0
N/M	Fib.	0,018489479	$(0{,}368385; 0{,}565943)$	0,80601955	36/0
N/M	Q/C	0,018489492	$(0{,}368386; 0{,}565942)$	0,80601955	24/12
N/M	Gold.	0,03125	$(1{,}45081; 0{,}266378)$	2,0944431	7/0
M/M	Fib.	0,018489479	$(0{,}368385; 0{,}565943)$	0,80601955	36/0
M/M	Q/C	0,018489492	$(0{,}368386; 0{,}565942)$	0,80601955	24/12
M/M	Gold.	0,03125	$(1{,}45081; 0{,}266378)$	2,0944431	7/0

inferior ao dos passos regularizados neste experimento. Na TP 15, a regularização evita uma direção de subida; Fibonacci e Q/C produziram custos próximos entre si.

Goldstein satisfez ambas as desigualdades nos nove casos, mas pode retornar redução menor por aceitar um passo suficiente em vez de minimizar a linha. Nos nove casos de cada busca, Fibonacci usou 342 avaliações de custo; Q/C, 324 de custo e 236 de gradiente; Goldstein, 47 de custo. Como os critérios de precisão e os custos de cada avaliação diferem, esses totais não demonstram superioridade universal de um método.

2.4 Testes extras

Foram executados mais 27 casos, sem substituir os obrigatórios, nos pontos TP 1: $(4, 2)$; TP 8: $(1, 0{,}5)$; TP 15: $(-0{,}5, 0{,}5)$. Todos apresentaram redução e valores finitos:

Função	Menor redução (%)	Maior redução (%)
TP 1	60,0000	100,0000
TP 8	62,8727	94,7387
TP 15	28,1026	53,4136

Os próximos pontos e diagnósticos extras estão no CSV/JSON. Os testes avaliam o primeiro passo; não provam convergência para qualquer inicialização.

3 Manual de uso

1. Instale Python 3 e as dependências e abra o Jupyter:

   ```
   python -m pip install numpy pillow matplotlib notebook
   python -m notebook
   ```

2. Mantenha os dois notebooks e a fotografia na pasta do trabalho. Abra `parte 1.ipynb` ou `parte 2.ipynb` e execute todas as células em ordem após reiniciar o kernel. Os notebooks são independentes.

3. **Entradas da Parte 1:** `NOME_IMAGEM` indica o arquivo; `LADO_MAXIMO`=256 controla a resolução; `TAU`=0,005 controla a suavização. A paleta é inicializada deterministicamente.

4. **Entradas da Parte 2:** `PROBLEMAS` contém funções e pontos iniciais; `PARAMETROS` contém tolerâncias, regularização e limites. Os padrões são os descritos na seção de experimentos.

5. **Saídas:** as células mostram imagens, tabelas e diagnósticos. `resultados/parte1` contém as reconstruções e `resultado_primeiro_passo.json`. `resultados/parte2` contém `resultados_obrigatorios.csv`, `resultados_extras.csv`, `experimentos.json`, resumo e gráficos.

6. Nas tabelas, leia direção solicitada/usada, passo, próximo ponto, custos, redução e avaliações. O JSON inclui parâmetros e históricos completos; use-o ou o CSV para valores com maior precisão que os arredondados neste relatório. Falhas têm diagnóstico explícito. Gradiente numericamente nulo gera status `estacionario`, passo zero e nenhuma busca, sem exigir redução estrita ou afirmar mínimo global.

Teste interativo opcional. O notebook `testar_paleta.ipynb` permite escolher outra imagem sem executar os notebooks das Partes 1 e 2:

1. Abra o arquivo no Jupyter ou no VS Code com suporte a notebooks e selecione um kernel Python 3. Pelo terminal, na pasta do trabalho, também é possível abrir com:

   ```
   python -m notebook testar_paleta.ipynb
   ```

2. Execute todas as células em ordem. A primeira verifica e instala apenas as dependências ausentes: NumPy, Pillow, Matplotlib e ipywidgets. A instalação requer internet. Mantenha o kernel ativo para usar o painel.

3. Clique em "Escolher imagem", selecione o arquivo no computador e clique em "Gerar paleta". Para testar a imagem original, use "Usar foto do trabalho", quando ela estiver disponível na pasta.

4. Observe a imagem de trabalho, a reconstrução e as três cores em RGB (0 a 255) e hexadecimal. Para copiar os valores, selecione o texto na caixa de cores e pressione Ctrl+C. Para outra imagem, repita o upload.

5. Como alternativa ao painel, remova o comentário da chamada `testar_arquivo("minha_foto.jpe` na última célula e informe um caminho acessível ao computador do kernel.

A ferramenta executa o mesmo primeiro passo da Parte 1, sem alterar os resultados do trabalho; não busca convergência completa. O resultado fica na variável `ultimo_resultado`. Imagens com poucas cores podem retornar cores repetidas; gradiente nulo retorna a paleta sem busca.

As saídas são atualizadas a cada execução, sem sobrescrever a fotografia. PNG usa RGB de 8 bits; os cálculos e JSON mantêm ponto flutuante. O ambiente verificado utilizou Python 3.11.9, NumPy 2.4.6, Pillow 12.3.0 e Matplotlib 3.11.2.

A Auditoria de uso de IA

A.1 Resumo das solicitações

A IA foi utilizada para interpretar o enunciado, planejar o projeto, explorar temas, preparar a fotografia, formular o objetivo e suas derivadas, implementar as duas partes, verificar resultados e revisar o código. Também auxiliou na redação e implementou a ferramenta independente de teste de imagens, solicitada posteriormente. A escolha do tema e a fotografia são do autor. Os resumos das solicitações efetivamente registradas são:

1. compreender o trabalho e organizar o planejamento;
2. explorar aplicações de otimização e escolher a paleta de cores;
3. preparar a imagem e finalizar a implementação da Parte 1;
4. implementar e verificar os experimentos da Parte 2;

O histórico está em `resumo de prompts.md`. As contribuições estão descritas neste apêndice, e os erros detalhados constam de `auditoria critica de erros.md`.

A.2 Erro de implementação: omissão de pontos estacionários

O código gerado pela IA retornava uma lista vazia de direções quando a norma do gradiente era $\leq 10^{-12}$. O executor apenas percorria essa lista e omitia as nove combinações da função. O erro foi identificado testando a TP 1 em $(5, 6)$: o total caiu de 27 para 18 registros.

A análise mostrou que $\nabla f_1(5, 6) = 0$ e $f_1(5, 6) = 0$; as direções são nulas e $\phi(\alpha) = 0$. Logo, redução estrita é impossível, e não se deve forçar uma busca de descida nem omitir o caso. A correção em `executar_casos` preserva os nove registros com status `estacionario`, passo zero, ponto e custo inalterados e nenhuma busca. Goldstein fica não aplicável; não se afirma que todo ponto estacionário seja um mínimo.

O teste de regressão confirmou 27 registros, nove estacionários da TP 1, sem iterações de busca. O ponto inicial original foi restaurado, e ambos os notebooks foram reexecutados sem erros. Os resultados originais da Parte 1 e dos 54 casos da Parte 2 permaneceram idênticos.

Também ocorreram dois erros de sintaxe ao gerar textos das células, com strings não encerradas. Foram corrigidos removendo substituições redundantes de barras invertidas e usando `chr(10).join(texto)` na exportação do resumo. Os diagnósticos e as validações estão no arquivo de auditoria. A ausência de descida de Newton nas TP 8 e TP 15 é uma propriedade matemática tratada pelo algoritmo, não um erro da IA.

Referências

[1] CELEBI, M. Emre. Improving the Performance of K-Means for Color Quantization. *Image and Vision Computing*, v. 29, p. 260–271, 2011. DOI: 10.1016/j.imavis.2010.10.002. Versão disponível em: `https://arxiv.org/abs/1101.0395`.

[2] ROSE, Kenneth. Deterministic Annealing for Clustering, Compression, Classification, Regression, and Related Optimization Problems. *Proceedings of the IEEE*, v. 86, n. 11, p. 2210–2239, 1998. Disponível em: `https://scl.ece.ucsb.edu/sites/default/files/publications/b98_2_0.pdf`.

[3] COELHO, Ricardo. *Primeiro Projeto Computacional: Modelagem e Busca Linear*. Programação Não Linear, UFC, 2026. Enunciado disponibilizado pelo professor.

[4] TIAGO. *Nascer do sol no Rio de Janeiro*. Fotografia digital, acervo pessoal do autor; data de captura não informada.